ДЗ-13: Патерни, тренди та кластеризація

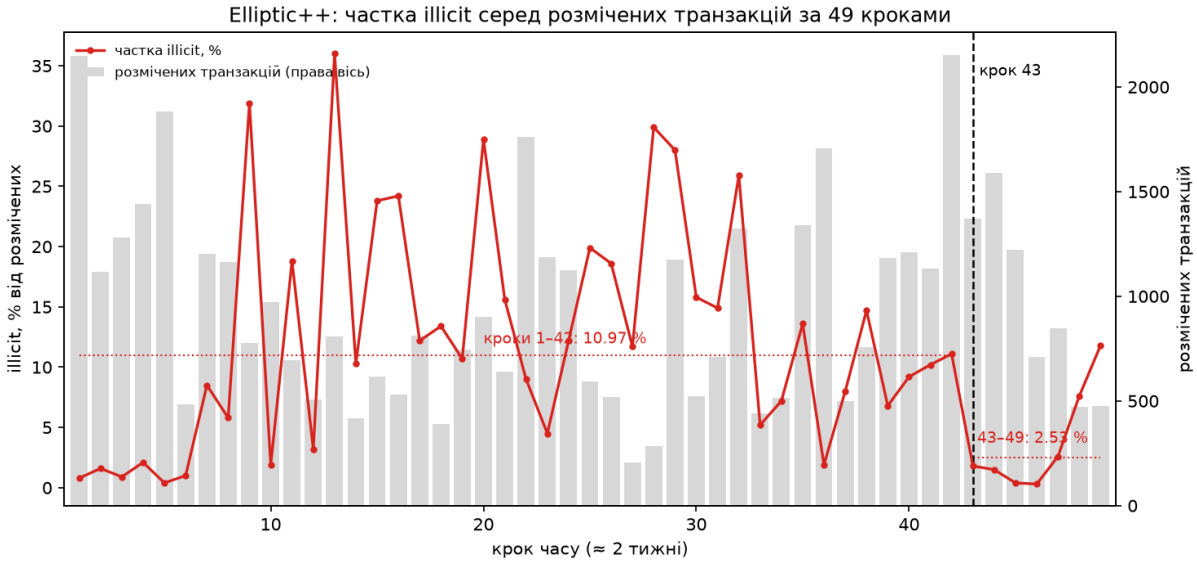
Прізвище Ім'я · Elliptic++ (Elmougy & Liu, KDD 2023) · Neo4j Community 2026.10.1 + GDS 2026.10.1 + APOC 2026.10.1 · Gephi Toolkit 0.11.4 · запуск 13.11.2026. Усі запити з порогами — у `queries.cypher`.

Підготовка

`prep.py` → `01_import.cypher` (≈ 2,5 хв). Підрахунки **збігаються з еталоном** (знімок — `import.png`):

Вузли й ребра	Transaction	Wallet	FLOWS_TO	INPUT	OUTPUT	SENT_TO
У моїй базі	203 769	822 942	234 355	477 117	837 124	2 775 637

Завдання 1. Тренд



Кроки	illicit	розмічених	частка illicit
1–42	4 376	39 877	**10,97 %**
43–49	169	6 687	**2,53 %**

Частки пораховано через суми `illicit / labelled`, а не як середнє відсотків. До кроку 42 частка стрибає від 0,4 до 36 %, а з кроку 43 падає до 0,3–1,8 % на кроках 43–46 і лише на 48–49 повертається до 7,6–11,8 %. Альтернативне пояснення, крім «злочинців стало менше»: близько кроку 43 закрився великий darknet-ринок (так пояснюють провал моделей після 43 автори оригінального Elliptic, Weber et al., 2019). Злочинна активність переходить на нові адреси й сервіси, які ще ніхто не атрибутував. Тобто падає покриття розмітки, а не злочинність: мітки — це «що відомо слідству», а не «що відбувалося».

Завдання 2. Патерни

2.1 Fan-in

Перцентилі кількості відправників: **p99 = 46, p99.9 = 103, max = 11 213**. Поріг 103 (p99.9) — «хвіст» розподілу, а не число «на око». Його перевищують 833 гаманці:

Клас	гаманців ≥ 103 відправників	частка	базова частка	lift
illicit	22	2,6 %	1,7 %	1,5
licit	453	54,4 %	30,5 %	1,8
unknown	358	43,0 %	67,8 %	0,6

Висновок: fan-in сам по собі не є ознакою злочинної активності: серед «консолідаторів» licit-гаманців у 20 разів більше, ніж illicit, а lift у licit вищий. Це насамперед біржі, платіжні сервіси й пули, і без другого сигналу fan-in дає хибні спрацювання.

2.2 Peel chain

Поріг «відщепу» outMin / outMax	< 0,1	< 0,05	< 0,01 (додатково)
illicit-транзакцій, з яких починається ланцюжок із 5 переходів	**366**	**357**	189

Висновок: зміна порогу з 0,1 на 0,05 прибрала лише 9 стартів (−2,5 %). Отже, у знайдених ланцюжках «відщеп» майже завжди менший за 5 % від решти: дрібна виплата і велика решта на нову адресу, крок за кроком. Форма різка й стабільна до порогу. Лише при порозі 0,01 лишається 189 стартів: приблизно в половини ланцюжків усі п'ять відщепів менші за 1 %, а в решти хоча б один лежить між 1 і 5 %.

2.3 Експозиція

unknown-гаманець	exposure (illicit за 1–2 кроки)	прямі відправники
`18sJPXgoWoL3Z1pcM22QvWwyyFVhwxrXE9`	1 061	1: `1FvtWwP3…` (illicit, сам має 1 060 illicit-відправників)
`1781T3nnX2ncqTHYbRcac1R58VR1mFvmqt`	1 061	той самий 1 відправник `1FvtWwP3…`
`3BBio7imFnNJ2cJEMoArJ1QcBzS4NmvAfr`	319	33, з них 1 illicit (`3MnQyozU…`, за ним 318 illicit)

Висновок: рекордна експозиція 1 061 складається з 1 прямого illicit-відправника плюс 1 060 його власних illicit-відправників. Вона «успадкована» через одне ребро з вагою n = 1, тому це **слабкий** сигнал: адреса могла отримати одну виплату від консолідатора, нічого не знаючи про його джерела. Те саме з третьою адресою. Висока експозиція значуща, лише коли її дають багато незалежних шляхів.

Завдання 3. Спільноти

Весь `03_gds.cypher` (≈ 35 с): WCC — 2 компоненти (822 935 + 7); **Louvain — 385 спільнот, Q = 0,928**; Leiden — 435, Q = 0,926. У самоперевірці курсу вказано ≈ 410–450 спільнот, а в мене 385: Louvain недетермінований, модулярність збігається. Базова частка illicit серед гаманців — 1,73 %.

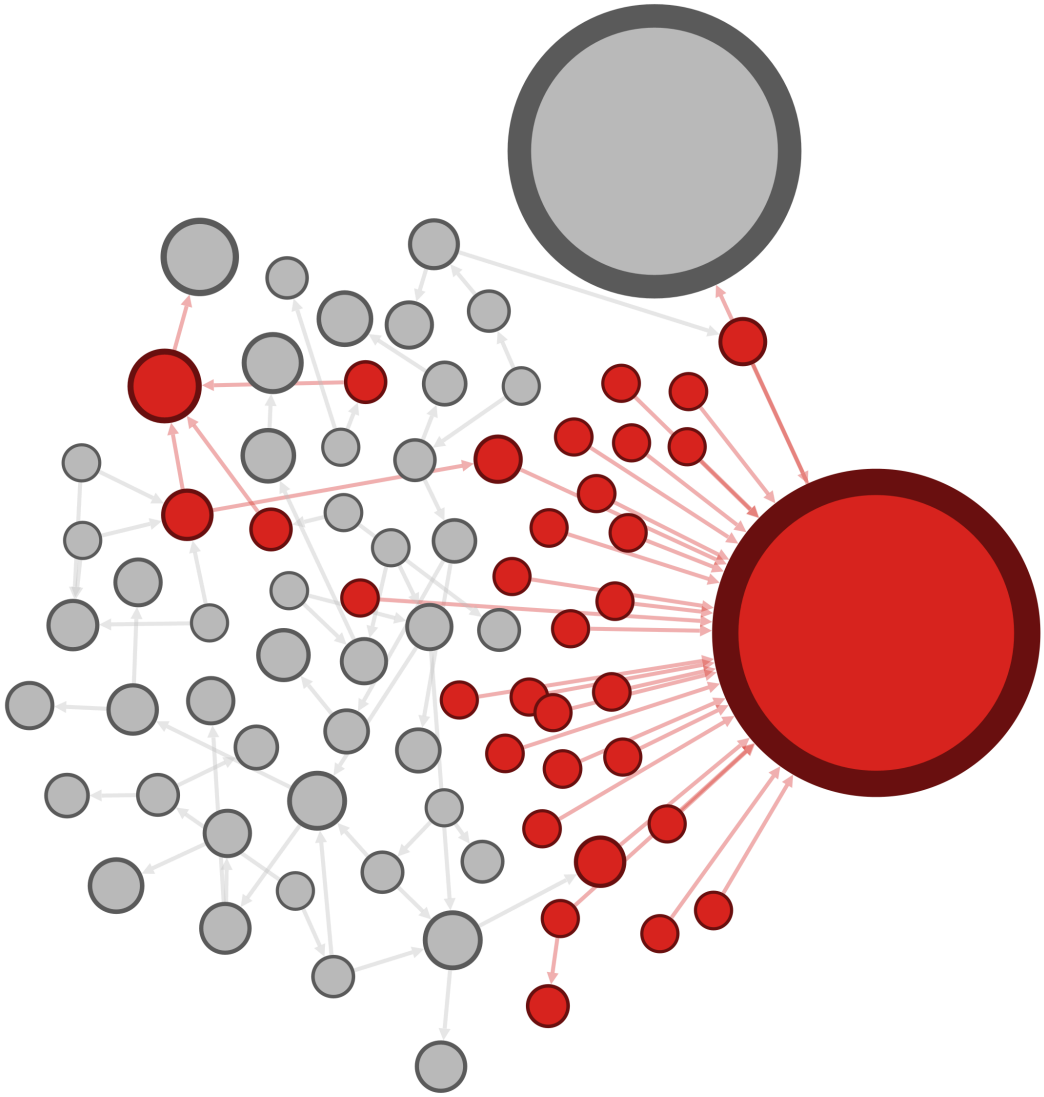
#	community	size	illicit	licit	illicitPct	lift
1	**476429**	78	33	0	42,3 %	**24,4**
2	744291	5 643	1 357	803	24,0 %	13,9
3	131194	3 161	715	1 078	22,6 %	13,0
4	370507	2 405	519	523	21,6 %	12,4
5	206855	84	18	23	21,4 %	12,4

У цьому запуску перше місце посіла мала спільнота (78 гаманців, усі активні лише на кроці 15). У довідковому запуску максимум був 28,2 % / lift 16,3. Кандидати в ліди — unknown із найвищим PageRank у спільноті 476429:

lead	pagerank	senders	receivers	крок
`1PMBzVZqD7uqsDr8LQKXFyXb7eggRUUfP9`	3,83	1	0	15
`19L3MtGJ16GXBF8gJmsLYz76KTjPPm6Jnk`	0,71	1	0	15
`17t2NY43e8ziZa2Ra8NbNfimij3sYuLMiv`	0,48	1	0	15

Обираю `1PMBzVZq…`: його PageRank уп'ятеро вищий за наступного, і саме він отримав від хаба спільноти `1FHFZAyf…` увесь зібраний баланс (див. завдання 4 і 5). Окремо помітно, що серед лідів з найвищим PageRank у `03_gds.cypher` (запит 8) перше місце посідає `1781T3nn…` із завдання 2.3 (PR 144,7). Його PageRank так само успадкований від хаба `1FvtWwP3…`.

Завдання 4. Gephi



Кольори й розмір: колір — Partition за `class` (червоний — illicit, сірий — unknown; licit у спільноті немає), розмір — Ranking за `pagerank`. Найбільший червоний вузол — хаб `1FHFZAyf…`, найбільший сірий — лід `1PMBzVZq…`. **Розташування illicit:** вони не розкидані по спільноті. Майже всі утворюють окреме скупчення-«зірку», що сходиться в хаб, а unknown-гаманці лежать окремо, ланцюжками переказів.

Спільноту вивантажено блоком B з `04_export.cypher` (78 вузлів, 82 ребра). Gephi GUI не встановлено, тому ті самі кроки виконано в Gephi Toolkit 0.11.4 (`tools/GephiCommunity.java`): ForceAtlas2 з Approximate Repulsion (Barnes-Hut), далі Prevent Overlap (adjustSizes), Partition за class, Ranking за pagerank, Preview → PNG/SVG, Save project → `community.gephi`.

Завдання 5. Висновок про лід

Лід: `1PMBzVZqD7uqsDr8LQKXFyXb7eggRUUfP9` (unknown). Це найвищий PageRank серед unknown у спільноті Louvain 476429, першій у топ-5: 78 гаманців, 42,3 % illicit, lift 24,4, жодного licit.

Сигнал А — сусідство за мітками. У ліда один відправник — illicit-гаманець `1FHFZAyf…`. На кроці 15 у нього зайшли кошти від 29 гаманців, і всі 29 мають мітку illicit.

Сигнал Б — форма транзакції, без міток. Лід отримав увесь вихід транзакції 246979279: 29 вхідних потоків, 1 вихід 14,989 BTC, без решти. Це консолідація з повним «sweep» на нову адресу, після якого кошти в межах датасету не рухаються. Серед 171 гаманця, що отримували такий sweep (1 вихід, ≥ 20 вхідних потоків), illicit — 12,9 % (lift ≈ 7,5). Сигнал рахується з форми транзакції без жодних міток, тому не випливає з міток чи спільноти.

Спільноту окремим сигналом не рахую: лід має одне ребро, тож членство в ній успадковане від хаба. Leiden кладе лід у спільноту з 5 087 гаманців, де illicit лише 6,8 % (lift ≈ 3,9).

Альтернативи: (1) депозитна адреса біржі чи обмінника, куди злочинець вивів кошти; тоді адреса належить сервісу; (2) холодне зберігання того самого оператора; (3) неповна розмітка: сама транзакція 246979279 має клас unknown, а мітки гаманців в Elliptic++, судячи з даних, виведено з міток транзакцій, тож лід «unknown» за побудовою; (4) хибна мітка хаба: якщо `1FHFZAyf…` — сервіс, сигнал А зникає.

Упевненість: помірна. Два незалежні сигнали узгоджені, але обидва стосуються одного кластера на одному кроці, а відрізнити «гаманець оператора» від «депозиту біржі» в межах датасету неможливо.

Наступний крок: у block explorer (mempool.space, Blockchair) подивитися, куди й коли пішли 14,989 BTC після кроку 15 і чи з'являється адреса у спільних входах з іншими. Далі — відкриті атрибуції: WalletExplorer/OXT (чи адреса в кластері відомого сервісу), Chainabuse, OFAC SDN (чи згадуються лід або `1FHFZAyf…`).

Примітка про мітки

Жоден unknown-гаманець не бере участі в жодній із 4 545 illicit-транзакцій (запит 5.5). Отже, мітки гаманців в Elliptic++ виведено з міток транзакцій. Тому «unknown» означає «не торкався розміченої illicit-транзакції», а не «перевірений і чистий». Через це сигнал «отримав кошти з illicit-транзакції» для unknown неможливий, і для другого сигналу я взяв форму транзакції.